

Introdução à Inteligência Artificial

-Trabalho Prático nº 2 2025/2026-

Problema de Otimização



Artur Meireles de Sousa Falcão

-2024130485

Gabriel Cardoso Rodrigues

-2024133397-

Índice

Introdução -----	3
Representação das soluções -----	3
Função de avaliação -----	3
Tratamento de soluções inválidas -----	3
Algoritmos implementados -----	4
Justificação das opções tomadas -----	5
Resultados e análise -----	5
Conclusões -----	6

Introdução

O trabalho prático proposto na unidade curricular de Introdução à Inteligência Artificial consiste na implementação de métodos de otimização aplicados ao problema de seleção de m locais, de um conjunto de C candidatos, de forma a maximizar a distância média entre os locais escolhidos.

Foram implementados três métodos de otimização:

- Pesquisa local (Trepá-colinas);
- Algoritmo evolutivo (EA);
- Métodos Híbridos (combinação de EA + LS)

Representação das soluções

A solução é representada por um vetor binário de dimensão C , onde:

- $\text{sol}[i] = 1$ - o local i é selecionado
- $\text{sol}[i] = 0$ - o local não é selecionado

O número total de posições a 1 é sempre igual a m , conforme a restrição do problema.

Função de avaliação

O fitness de uma solução é dado pela média das distâncias entre todos os pares de pontos selecionados, onde:

- $\text{dist}(i, j)$ é a distância entre os pontos i e j , pré-carregada a partir da instância;
- Apenas pares selecionados contribuem para o somatório.

Sendo o objetivo maximizar o fitness, ou seja, maximizar a média das distâncias.

Tratamento de soluções inválidas

Uma solução é inválida quando contém:

- Mais que m elementos selecionados;
- Menos que m elementos selecionados.

Estratégia adotada de REPARAÇÃO após qualquer mutação ou recombinação:

- Se houver excesso de 1's - remove-se aleatoriamente até atingir m .
- Se houver falta de 1's - adicionam-se aleatoriamente até atingir m .

Isto garante que todas as soluções usadas no processo evolutivo e na LS são válidas.

Algoritmos implementados

Pesquisa local – Trepa-colinas

Estrutura geral

- Gerar solução inicial válida;
- Avaliar solução;
- Gerar todos os vizinhos possíveis;
- Selecionar o melhor vizinho;
- Substituir caso exista melhoria;
- Repetir até ao limite de iterações.

Vizinhanças utilizadas

1. Swap simples
 - Remove 1 ponto selecionado;
 - Adiciona 1 ponto não selecionado;
 - Distância de Hamming = 2.
2. Double swap (permite explorar regiões mais distante do espaço de soluções)
 - Remove 2 selecionados;
 - Adiciona 2 não selecionados;
 - Distância de Hamming = 4.

Algoritmo evolutivo – EA

Seleção

1. Torneio binário
 - Dois indivíduos são escolhidos;
 - O melhor vence.
2. Roleta
 - Probabilidade proporcional ao fitness;
 - Permite diversidade maior.

Operadores de recombinação

1. Crossover a 1 ponto
 - Divide o vetor num ponto e troca as partes.
2. Crossover uniforme
 - Cada gene é escolhido de um dos pais com probabilidade 0.5.

Operadores de mutação

1. Bitflip
 - Inverte genes aleatoriamente;
 - Depois aplica reparação para manter m selecionados.
2. Swap
 - Troca um gene 1 com um gene 0 – mantém automaticamente m selecionados

Métodos Híbridos

Híbrido 1 – Memético (EA + LS a cada geração)

- Aplica LS aos melhores indivíduos gerados em cada geração;
- Forte intensificação local;
- Custo computacional maior.

Híbrido 2 – Refinamento inicial (LS antes do EA)

- A população inicial é otimizada com LS;
- O EA continua de forma normal;
- Mais leve e rápido.

Justificação das opções tomadas

- A representação binária é simples, eficiente e adequada ao problema;
- A reparação é preferível para soluções inválidas, pois garante que nunca se avaliam soluções inválidas;
- As duas vizinhanças permitem explorar diferentes regiões do espaço de soluções;
- Os métodos de solução escolhidos (torneio e roleta) são clássicos e complementares;
- Os operadores de recombinação e mutação são adequados a vetores binários e mantêm boa diversidade;
- Os híbridos foram escolhidos para representar duas filosofias distintas:
 - Intensificação contínua (memético);
 - Melhoria inicial (refinamento).

Resultados e análise

Foram realizados testes com 10 runs para cada método, usando várias instâncias e combinações de parâmetros. Apresentam-se abaixo os indicadores:

- AVG – média do melhor fitness de cada run;
- BEST – melhor solução global obtida nas 10 runs.

Para garantir comparação justa entre métodos, alguns parâmetros foram mantidos constantes em todos os testes:

- Vizinhança utilizada pela LS: double-swap;
- Número de gerações do EA: 1000;
- Indivíduos sujeitos a LS no Hybrid1 : 1 por geração.

Pesquisa local

Foram testadas diferentes combinações de:

- Número de iterações: 1, 50, 500;
- Execução de instâncias: tourism_5, 20, 50, 100, 250, 500.

A análise das médias obtidas demonstra que o melhor desempenho foi alcançada com:

- Iterações: 500;

Observa-se que o aumento do número de iterações conduz a melhorias consistentes no AVG, e o comportamento evidencia que a vizinhança double-swap possibilita explorar regiões mais amplas do espaço de soluções.

Algoritmo Evolutivo

No EA foram avaliadas as seguintes parametrizações:

- Tamanho da população: 20, 100;
- Probabilidades de recombinação: 0.6, 1.0;
- Probabilidades de mutação: 0.01, 0.1;
- Operadores de recombinação: 1-ponto, uniforme;
- Operadores de mutação: swap, bitflip;
- Métodos de seleção: roleta, torneio.

Após análise dos resultados médios, a melhor configuração encontrada foi:

- População: 100;
- Probabilidade de recombinação: 1.0;
- Probabilidade de mutação: 0.1;
- Seleção: torneio;
- Recombinação: 1-ponto;
- Mutação: swap;

A seleção por torneio demonstrou ser mais robusta, reduzindo o risco de convergência prematura em comparação com a roleta, que é mais sensível à escala dos valores de fitness, especialmente em instâncias maiores.

Por sua vez, a mutação swap produziu sistematicamente melhores resultados do que bitflip, porque mantém a estrutura da solução mais estável.

Populações maiores (100 indivíduos) comportam-se melhor devido à maior diversidade e menor risco de convergência prematura.

Probabilidade de recombinação de 1.0 e probabilidade de mutação de 0.1 mostraram-se a combinação mais eficaz.

Métodos Híbridos

Foram avaliados dois métodos Híbridos combinando AE com PL:

- Híbrido 1 – aplicação de Pesquisa Local após cada novo indivíduo gerado, antes de integrar a população;
- Híbrido 2 – Pesquisa Local aplicada periodicamente apenas aos melhores indivíduos.

Os resultados demonstram que o Híbrido 1 foi superior em todas as instâncias, onde a aplicação de Pesquisa Local em cada indivíduo reforçou a intensificação e acelerou a convergência. O Híbrido 2 apresenta melhoria face ao EA, mas é consistentemente inferior ao Híbrido 1 devido à menor frequência de refinamento. Ambos superaram a Pesquisa Local isolada.

Conclusões

A realização deste trabalho permitiu comparar técnicas distintas de otimização aplicadas ao problema de maximização da distância média entre pontos.

A Pesquisa Local revelou-se eficaz em instâncias pequenas e com tempo reduzido de computação, o Algoritmo Evolutivo mostrou maior capacidade de exploração em problemas maiores mas convergência mais lenta, e os Métodos Híbridos alcançaram o melhor desempenho global. Em particular, o Híbrido 1 evidenciou-se como a abordagem mais robusta e consistente, comprovando que a combinação de evolução populacional com a intensificação local pode produzir soluções de qualidade superior. Assim, conclui-se que a integração de Pesquisa Local no processo evolutivo representa o melhor compromisso entre qualidade de solução e capacidade de exploração do espaço de procura.

Para além dos resultados, este trabalho permitiu compreender na prática o impacto das escolhas de representação, operadores e estratégias de intensificação, reforçando que os métodos híbridos podem superar técnicas isoladas em problemas combinatórios de otimização.